

# 中南大学

## 研究生学位论文开题报告

姓 名 : 李世尧

学 号 : 244811088

论 文 题 目 : 用于高维空间变化岩石性质反演分析  
的可微有限元框架研究

课 题 来 源 : 国家自然科学基金项目

攻 读 学 位 : 工学硕士学位

指 导 教 师 : 苏晶晶

学 科 专 业 : 土木工程

二 级 单 位 : 土木工程学院

填 表 日 期 : 2025 年 11 月 13 日

## 一、选题意义和研究价值

### 1.1 选题意义

在隧道工程、边坡支护、大坝建设及地下空间开发等重大岩石工程中，岩体力学参数的准确获取是进行工程设计、施工期安全控制与长期稳定性评价的根本前提。与均质的工业材料不同，天然岩体经过长期的地质构造运动，内部呈现出高度的非均质性，其力学参数（如弹性模量、泊松比、粘聚力、内摩擦角等）在空间上并非一个常数，而是呈现出复杂的、连续或非连续的分布特征。这种参数的空间变异性直接控制着工程岩体的变形模式、应力分布和潜在破坏路径，是导致工程失稳破坏的关键内因。因此，如何精确地反演并重构岩体内部的非均质力学参数场，已成为岩石力学与岩土工程领域一个亟待解决的核心科学难题。



图 1 马尔帕塞拱坝遗址



图 2 崩塌后修缮工作

在重大岩石工程实践中，对岩体力学参数的精准掌握是保障工程安全与经济性的生命线。无论是隧道或是大坝，其设计的根基、施工的安危乃至长期的稳定运营，都直接取决于我们对这片“非均质”岩体的认知深度。然而，工程实践中却不乏因对岩体参数认识不足而导致的惨痛教训。例如，20世纪50年代法国马尔帕塞拱坝的垮塌事故，其重要原因之一便是对坝基岩体的复杂地质结构和力学特性评估不足，导致了灾难性的工程失效。在国内，类似的问题同样存在，部分公路边坡或隧道工程在运营期间出现的变形、开裂甚至失稳，也往往与前期勘察未能准确揭示岩体内部力学参数的空间变异性，导致设计模型与实际情况严重不符有关。这些案例表明，一个微小的参数偏差，在巨大的工程应力作用下都可能被无限放大，最终演变为难以挽回的工程灾害。

因此，在施工之前，通过有效手段“透视”并重构工程区域内的岩体力学参数场，就显得至关重要。这不仅能帮助工程师制定出更具针对性、更安全可靠的设计方案，还能在施工过程中，通过实时监测数据的反馈，动态评估岩体稳定性，及时预警潜在风险，从而采取主动性、预防性的支护措施。可以说，对非均质岩体参数的精确反演，是从源头上降低工程风险、提升工程建设质量和实现全生命周期安全管控的核心技术前提。

目前，逆分析是利用有限的现场监测数据（如地表位移、围岩收敛、锚杆轴力等）来反推岩体力学参数的主要手段。然而，作为当前反推岩体力学参数的主要技术手段，传统的逆分析方法在面对大规模非均质参数场时仍然难以处理。首先，为了精细刻画岩体的非均质性，需要将岩体划分为成千上万个单元，这使得待反演的参数数量急剧膨胀至高维空间，传统的优化算法在此“维度灾难”面前束手无策，难以收敛到有效解。其次，高效的梯度优化算法又因商业有限元软件的“黑箱”特性而陷入“梯度困境”，无法获取精确的梯度信息，导致计算成本高昂且不切实际。最后，岩石固有的弹塑性等强非线性力学行为，进一步加剧了逆问题的病态性，使得求解过程极为

困难，解的唯一性和稳定性也难以保证。这些瓶颈共同制约了传统方法在实际工程中的应用深度和广度。

近年来，以 JAX、PyTorch 和 TensorFlow 为代表的可微分编程（Differentiable Programming）框架为解决上述困境带来了新思路。这些框架的核心技术——自动微分（Automatic Differentiation, AD），能够对任意由基本可导函数构成的复杂计算程序进行精确、高效的求导。基于此，一种名为“可微分物理仿真”的新范式应运而生。其核心思想是将经典的物理求解器 FEM 的整个计算流程，完全用可微分的函数进行重构。这样，整个物理求解器就从一个不可求导的“黑箱”，转变为一个端到端可微分的“白箱”函数。该函数以物理参数为输入，以物理场的响应（如位移场）为输出，并且可以自动、精确地给出输出对于任意输入的梯度。

这一新兴范式为解决高维物理逆问题提供了全新的工具。它允许我们将复杂的物理模型（FEM）直接嵌入到基于梯度的现代优化框架中，从而能够利用 GPU 加速，高效地求解包含数万甚至数百万未知参数的逆问题。尽管可微分物理仿真在流体力学、图形学等领域已展现出巨大潜力，但其在岩石力学，特别是针对考虑复杂弹塑性本构的大规模非均质参数场反演问题上的系统性应用，尚属空白。

因此，本研究拟将可微分物理仿真这一前沿计算科学范式，引入到经典的岩石力学逆分析问题中。通过构建一个端到端可微分的弹塑性有限元求解器（AD-EPFEM），旨在突破传统逆分析方法在“维度灾难”和“梯度困境”上的根本性限制，建立一种能够从稀疏观测数据中高效、高精度反演岩体高维非均质参数场的新理论与新方法。这项研究不仅有望为解决岩石工程中的核心技术难题提供关键工具，也顺应了“人工智能驱动的科学发现（AI for Science）”这一重大发展趋势。

## 1.2 选题价值

本研究旨在将前沿的可微分物理仿真技术与传统的岩石力学逆分析问题相结合，其研究价值主要体现在应用和学术两个层面。

首先在其应用潜力上，通过从有限的现场监测数据中精细反演岩体内部的非均质力学参数分布，例如识别出未曾探明的软弱夹层，本方法能够极大提升数值模型的预测精度，为重大岩石工程的稳定性评估、灾害预警和动态设计调整提供更可靠的依据。这进一步为构建与物理实体实时同步的工程“数字孪生”提供了核心的参数标定引擎，对于实现工程全生命周期的智能化管理与风险控制具有至关重要的作用。同时，该方法能最大化利用非接触式监测数据的信息价值，有望在一定程度上减少对昂贵钻孔取样的依赖，从而降低工程勘察成本与风险。

在学术层面，本研究的价值在于其方法论的范式创新。它将经典的计算力学（有限元法）与新兴的计算科学（可微分编程）进行深度融合，构建了一个“物理模型即神经网络层”的全新计算框架，突破了传统逆分析中物理模型与优化算法相分离的“黑箱”模式，为解决各类物理科学中的高维逆问题提供了重要的理论参考。这项工作是“人工智能驱动的科学发现（AI for Science）”在地球科学与工程领域的具体实践，将有力推动人工智能技术与传统岩土工程学科的交叉融合。此外，该框架允许在损失函数中灵活地引入基于物理和地质先验知识的正则化项，并利用自动微分技术将其无缝整合进优化过程，为在数据稀疏条件下解决逆问题固有的不稳定性、获得物理上合理的解提供了新的理论途径。

## 二、国内外研究现状和发展动态

### 2.1 岩石力学逆分析的理论与方法研究现状

岩石力学逆分析旨在利用工程现场的监测信息（如位移、应力等）反向推断难以直接测量的岩体力学参数或边界条件，其数学本质属于典型的不适定性问题，即解的存在性、唯一性和稳定性通常无法得到保证。自 20 世纪 70 年代以来，随着计算机技术的发展，该领域的研究方法经历了显著的演进。

早期的研究主要依赖于解析或半解析解。例如，Sakurai (1983) 提出了基于隧道现场收敛观测数据来估算围岩初始应力场和变形模量的经典方法，这类方法原理清晰，但仅适用于几何形状和地质条件高度简化的理想情况。为了处理更复杂的工程问题，研究范式转向了以“数值模拟联合优化算法”为核心的现代计算框架。在该框架下，根据所采用优化算法的不同，主要形成了两大技术框架。

第一个框架是采用梯度无关的智能优化算法。自 20 世纪 90 年代起，遗传算法 (GA)、粒子群优化 (PSO)、模拟退火 (SA) 等启发式算法因其无需目标函数的梯度信息、具有全局搜索能力而被广泛应用。例如，Feng 和 An (2006) 结合有限元软件与改进的粒子群算法对某水电站地下厂房的围岩力学参数进行了反演。Deng 和 Lee (2001) 则利用遗传算法对边坡的岩土参数进行了识别。这类方法在处理参数维度较低的逆问题时表现良好，但其核心缺陷在于“维度灾难”：当需要精细刻画非均质岩体，将参数场划分为成百上千个单元时，算法的搜索空间呈指数级增长，导致计算成本过高，几乎无法收敛到可靠解。

第二个则是采用基于梯度的优化算法，如共轭梯度法、拟牛顿法 (BFGS) 等。这类算法利用目标函数的梯度信息指导搜索方向，收敛速度远快于智能算法。然而，其应用的核心瓶颈在于梯度的获取。由于数值模拟软件通常是“黑箱”，研究者不得不采用敏感度分析，即通过有限差分法来近似计算梯度。这意味着，对于包含一个待反演参数的问题，估算一次梯度就需要执行次完整且耗时的正向数值模拟。尽管这种方法在一些研究中被采用，如 Gioda 和 Maier (1980) 的开创性工作，但其高昂的计算成本使其在面对高维参数场反演时同样不具备可行性。为了解决梯度计算效率问题，部分学者引入了伴随法 (Adjoint Method)，该方法在地球物理勘探领域由 Tarantola (1984) 和 Plessix (2006) 等人发展成熟，能够以约等于一次正向模拟的计算量获得所有参数的梯度。但在岩石力学领域，由于其复杂的数学推导和在现有商业软件框架下实现的困难，其应用仍非常有限。

此外，为了处理逆问题的不确定性，以贝叶斯理论为基础的概率反演方法也得到了发展。如 Jiang 和 Huang (2016) 利用马尔可夫链蒙特卡洛 (MCMC) 方法对隧道围岩参数进行了概率反演，得到了参数的后验分布。但此类方法需要数万次采样，每次采样都可能涉及一次正向模拟，其巨大的计算量使其目前仅适用于低维问题。综上，现有逆分析方法在处理高维非均质参数场时，普遍受限于“维度灾难”或“梯度困境”，难以满足现代岩石工程精细化建模的需求。

### 2.2 传统有限元法在正向与反向分析中的应用现状

有限元法作为计算力学领域最成熟的数值方法，是现代岩石工程分析的基石。其在正向与反向分析中所扮演的角色和表现出的能力有显著差异。

在正向分析中，FEM 作为“物理模拟器”的技术已高度成熟。以 Abaqus, FLAC3D, Midas GTS

NX 等为代表的商业软件，以及 MOOSE 等开源框架，提供了强大的模拟能力。这些工具内置了丰富的岩土材料本构模型，从经典的摩尔-库仑、德鲁克-普拉格模型，到能够描述应变软化、蠕变、损伤演化的复杂模型，如 Cai 等人（2004）提出的考虑岩体结构面影响的综合本构模型。同时，FEM 能够处理极其复杂的工程地质几何、非线性接触以及流固耦合、热力耦合等多场问题。例如，Rutqvist 和 Stephansson（2003）系统综述了利用 TOUGH-FLAC 程序进行热-水-力（THM）耦合分析在核废料处置等领域的应用。这些经过大量工程实践验证的 FEM 工具，其计算结果的可靠性得到了业界广泛认可，是当前岩石工程设计与安全评估不可或缺的手段。

然而，当 FEM 被用于反向分析时，其优势在很大程度上转变为制约瓶颈。在上面所述的“数值模拟+优化算法”框架中，FEM 的角色是为优化算法提供目标函数值的“评估器”。正是在这个角色中，传统 FEM 算法或者软件的半封闭特性构成了根本性障碍。用户通常只能通过预设的接口输入参数并获取最终的计算结果，无法访问其内部的求解过程和中间变量。这一特性直接导致了上一节所述的“梯度困境”，即无法直接获取目标函数相对于待反演参数的解析梯度。此外，整个逆分析流程的效率也因 FEM 的此特性而大打折扣。典型的逆分析流程涉及外部优化脚本（如用 Python 或 MATLAB 编写）与 FEM 软件之间反复的数据交换：优化器生成参数文件，随后命令行调用 FEM 软件执行计算，等待计算完成后，外部程序读取并解析庞大的结果文件。这种基于文件 I/O 的松散耦合方式，流程繁琐，且大量时间被浪费在程序的重复启动、关闭和文件读写上，进一步恶化了本已高昂的计算成本。因此，尽管传统 FEM 在正向模拟中无比强大，但其半封闭和高昂的单次计算成本，使其成为制约岩石力学逆分析向高维度、精细化发展的核心技术瓶颈。

### 2.3 可微分物理仿真与 PINN 的研究现状与发展趋势

为突破传统逆分析方法的瓶颈，近年来，在“AI for Science”浪潮的推动下，两种利用自动微分（Automatic Differentiation, AD）技术获取梯度的新范式——物理信息神经网络（PINN）和可微分物理仿真——成为研究前沿，为解决“梯度困境”提供了全新思路。

物理信息神经网络（PINN）由 Raissi 等人（2019）正式提出，它利用深度神经网络作为偏微分方程（PDE）的通用函数逼近器，直接近似 PDE 的连续解。其核心创新在于将物理方程残差、边界/初值条件作为损失函数的一部分，与数据损失共同优化。对于逆问题，未知物理参数可作为网络的可训练变量一同学习。PINN 的无网格特性使其在处理不规则几何域问题时具有优势，并已在流体力学、热传导等领域取得成功。然而，在应用于复杂的岩石力学问题时，PINN 面临显著挑战。首先，其物理约束是“软”的，在训练困难或梯度病态时（Lu 等人, 2021），网络可能学习到违反物理定律的伪解。其次，标准 PINN 难以处理岩石材料复杂的弹塑性、应变软化等强非线性本构关系，以及断层、节理等不连续面力学行为。虽然有研究如 Haglund 等人（2022）尝试将塑性理论融入 PINN，但其通用性和鲁棒性仍有待验证。

与 PINN 并行发展的另一条路径是可微分物理仿真，特别是可微分有限元法。该方法思想更为直接：它并非用神经网络替代求解器，而是将成熟的 FEM 求解器本身，用支持自动微分的编程框架（如 JAX, PyTorch, TensorFlow）重写或改造，使其变为一个完全可微分的计算图。这意味着从输入参数到输出场量的整个 FEM 模拟过程，在数学上是一个可导函数。利用自动微分的反向传播模式，仅需一次正向模拟和一次反向传播，即可获得损失函数相对于所有输入参数的精确解析梯度，其计算成本与参数维度基本无关。近年来，这一方向涌现出诸多开创性工作，例如，

Takatani 等人 (2022) 开发了基于 JAX 的开源可微分有限元库 JAX-FEM，展示了其在拓扑优化和逆分析中的巨大潜力；Huang 等人 (2021) 在晶体塑性领域实现了可微分的 CPFEM，成功反演了高维材料参数。

发展趋势表明，可微分求解器正成为解决大规模科学与工程逆问题和设计优化的新范式。相比 PINN，可微分 FEM 继承了传统 FEM 的物理完备性，其物理约束是“硬”的，在每个求解步中都得到精确满足，因此解的物理可靠性更高。它为解决高维、非均质岩石力学逆问题提供了一条比 PINN 更稳健、更符合物理本质的路径。然而，当前可微分 FEM 的研究主要集中在线弹性或简单的非线性问题上。将其扩展到能够高效处理岩石力学中常见的复杂弹塑性本构、接触、损伤以及大规模非均质场反演，是该领域一个值得探索和深入的方向。

### 三、主要研究思路、研究内容和在学术方面的创新点

#### 3.1 研究目标

本研究旨在针对岩石力学高维逆分析的“梯度困境”瓶颈，以开源可微分有限元库JAX-FEM为基础进行二次开发，构建可微分弹塑性有限元求解器，并建立一套高效的反演方法，最终实现从稀疏观测数据中精确、快速地重构高维非均质岩体力学参数场，为岩石工程精细化建模提供新范式。

#### 3.2 研究内容

基于上述研究目标，本研究将围绕“构建可微分求解器—搭建逆分析框架—验证与应用”这一核心技术路线，分三步展开，具体研究内容如下：

##### （1）可微分弹塑性有限元求解器的构建与验证

本研究旨在构建并验证一个可微分弹塑性有限元求解器。首先，基于 JAX-FEM 框架并利用 JAX 函数式编程和可微分原语，实现完全可微分的 Drucker-Prager 弹塑性本构模型及其返回映射算法。接着，将该本构模型无缝集成到非线性有限元求解流程中，构建一个以网格、材料参数、荷载及边界条件为输入，通过牛顿-拉夫逊法迭代求解并输出位移、应力、应变场的端到端可微分正向求解器。最后，通过设计经典弹塑性力学基准问题，将本求解器的模拟结果（如应力-应变曲线、位移云图、塑性区分布）与开源有限元软件（Moose）的结果进行交叉对比，以验证其物理准确性。

##### （2）基于可微分求解器的高维逆分析框架搭建

在验证了正向求解器可靠性的基础上，我们将搭建一个高效的高维参数反演框架。此框架将正向求解器作为核心的“物理引擎”，并利用其可微分特性赋能梯度优化。

对逆分析问题数学建模，将岩体力学逆分析问题形式化为一个大规模的优化问题。目标函数定义为有限元模拟计算出的位移与稀疏的“现场”观测点位移之间的均方误差。优化变量是描述岩体非均质性的高维参数场，即每个有限元单元的力学参数(如弹性模量场  $E(x,y)$ 、粘聚力场  $c(x,y)$  等)。

进行高效梯度计算与优化器集成，利用 JAX 的自动微分 (AD) 功能，直接对整个“参数输入、FEM 模拟、损失函数计算”的计算图进行求导。这使得我们仅需一次正向模拟和一次反向传播，即可获得损失函数相对于所有单元力学参数的精确解析梯度。将此高效的梯度计算能力与先进的梯度下降优化器（如 Adam、L-BFGS）相结合，形成完整的逆分析迭代流程。

**正则化与先验信息融合：**考虑到岩土逆问题的不适定性，为提高反演结果的稳定性和物理真实性，我们将在损失函数中引入正则化项。例如，可以引入总变分正则化或高斯平滑先验，以鼓励反演出的参数场在空间上具有一定的平滑性或分块常数的特性，避免出现不切实际的、像素噪声般的反演结果。

##### （3）数值算例验证与典型工程问题应用

最后，我们将通过一系列精心设计的数值实验，全面评估所提方法的性能，并探索其在实际工程问题中的应用潜力。

包括综合性能对比验证，如设计一系列二维数值算例，系统地研究本方法在不同条件下的表现。我们将预设具有不同特征（如层状、含软弱夹层、随机分布）的真实参数场，并从中生成稀

疏、含噪的观测数据。通过与传统的逆分析方法在反演精度、计算效率、收敛稳定性和抗噪声能力等方面进行定量对比，充分展示本方法的优越性。

还将包括典型岩石工程问题应用研究：将本方法应用于更贴近实际的工程场景，例如隧道开挖问题。我们将模拟隧道开挖后，在围岩表面布设监测点获取位移数据。利用这些数据，反演隧道围岩的非均质力学参数分布，旨在识别出模型中预设的、未知的软弱带或高应力区域。此项研究将检验本方法在处理复杂几何、施工步骤和应力重分布问题时的有效性和实用性，并评估其在辅助工程地质勘察、预测潜在风险方面的应用前景。

### 3.3 论文大纲

#### 第一章 绪论

1.1 研究背景与意义

1.2 国内外研究现状

1.3 主要研究内容与技术路线

1.4 论文的组织结构

#### 第二章 岩石力学逆分析的相关理论基础

2.1 岩石力学逆问题的不稳定性与正则化方法

2.2 弹塑性有限元法基本理论

2.3 自动微分（AD）技术原理

#### 第三章 可微分弹塑性有限元求解器的构建

3.1 JAX-FEM 框架分析与二次开发策略

3.2 可微分本构模型的实现

3.3 端到端可微分弹塑性求解流程的整合

3.4 正向求解器精度验证：与开源软件 Moose 的对比

#### 第四章 基于可微分求解器的高维逆分析方法

4.1 高维非均质参数场逆分析的数学建模

4.2 基于自动微分的梯度计算与优化框架

4.3 正则化方法的引入与实现

#### 第五章 数值算例验证与分析

5.1 算例设计与评价指标

5.2 不同非均质特征参数场的反演

5.3 方法性能对比分析

5.4 观测数据稀疏度与噪声水平影响分析

#### 第六章 隧道开挖工程应用研究

6.1 工程背景与计算模型建立

6.2 隧道开挖过程的模拟与观测数据生成

6.3 围岩非均质力学参数场反演与结果分析

6.4 方法在工程应用中的潜力与局限性探讨

#### 第七章 总结与展望

7.1 全文主要研究工作总结

7.2 取得的主要创新性成果

7.3 研究的不足之处

7.4 未来研究工作的展望

参考文献

致谢

### 3.4 拟解决的关键问题

为成功实现上述研究目标，本研究需重点攻克以下三个的关键科学与技术问题：

#### (1) 弹塑性本构模型可微分算法的实现

将可微分计算从弹性领域拓展至岩石力学核心领域的首要技术障碍。关键在于如何将包含条件判断和迭代过程的经典弹塑性本构算法在JAX函数式编程框架下进行重构，确保其在屈服、塑性流动和应力更新的全过程中保持端到端可微分。解决此问题需要深入理解自动微分原理与JAX的底层机制，并建立一套与传统FEM结果精确对标的验证流程，以保证求解器的物理可靠性。

#### (2) 高维逆问题的不适定性与优化收敛性

岩石力学逆分析本质上是不适定的，尤其在待反演参数维度极高（成千上万）而观测数据稀疏含噪时，优化过程极易陷入局部极小值或产生物理上不真实的振荡解。关键在于如何设计和引入有效的正则化方法（如总变分正则化、高斯平滑先验），将关于参数场空间分布的先验知识融入优化目标函数中，以约束解空间，保证反演结果的稳定性和物理合理性，并提升优化过程的收敛效率。

### 3.5 研究创新点

本研究的核心创新在于将可微分物理仿真的前沿思想引入传统的岩石力学领域，提出了一种旨在从根本上破解高维逆分析瓶颈的新范式。区别于将物理规律作为“软约束”的物理信息神经网络方法，本研究的新范式将成熟的弹塑性有限元法本身直接构建为可微分模型。这使得平衡方程、本构关系等物理控制方程作为“硬约束”在每个计算步中都得到满足，从而保证解的物理可靠性。更关键的是，通过自动微分技术，该范式能够以与参数维度无关的高效率获取精确梯度，解决了传统逆分析方法在高维问题上面临的“梯度困境”与“维度灾难”，为岩石工程的精细化参数反演提供了一条更稳健、高效的新路径。具体分为如下两部分：

**技术工具创新：**构建了可微分的弹塑性有限元求解器。本研究将在开源框架 JAX-FEM 的基础上，首次研发并集成可微分的弹塑性本构模型。通过对包含条件判断和迭代求解的返回映射算法进行函数式重构，实现了从材料参数到非线性力学响应全流程的端到端可微分。这不仅为本研究提供了核心计算工具，其成果本身也构成了一个可复用的、面向岩石力学领域的开源可微分计算模块。

**应用层面创新：**实现了对高维非均质岩体力学参数场的精确、高效反演。本研究将所构建的新范式应用于传统方法难以胜任的、待反演参数维度高达数万乃至更高的非均质场反演问题。通过将可微分求解器与正则化技术、梯度优化算法深度融合，能够从稀疏、含噪的观测数据中，重构出岩体内部复杂的力学参数空间分布，极大地提升了岩石力学逆分析的分辨率和实用性。

## 四、拟采取的研究方法和技术路线

### 4.1 拟采取的研究方法

为实现本研究的各项目标，将综合运用文献调研、可微分建模、数值实验等多种研究方法，具体如下：

(1) 文献调研及数据收集法：在研究初期，将系统性地开展文献调研工作。一方面，深入梳理岩石力学逆分析领域的经典理论与方法，重点分析传统智能优化算法和有限差分梯度法在处理高维非均质问题时面临的瓶颈。另一方面，紧密跟踪可微分编程、物理信息神经网络（PINN）等前沿技术在科学计算中的最新进展，为本研究的技术路线提供理论支撑和借鉴。在数据层面，本研究将主要采用“合成数据-反演”的研究范式。即首先预设具有典型地质特征的非均质参数场，然后通过可靠的正向模拟生成稀疏的、并可添加不同水平噪声的“观测数据”。这种方法能够为后续反演结果的精度评估提供客观、定量的依据。并结合可获取的真实实验数据，辅助进行结果评估和算法优化。

(2) 可微分物理建模与梯度优化法：这是本研究的核心技术方法。首先，基于对开源库 JAX-FEM 的二次开发，采用函数式编程思想重构经典的弹塑性本构算法，利用 JAX 的可微分控制流原语（如 `jax.lax.cond`）确保其全程可导，从而构建出端到端可微分的弹塑性有限元正向求解器。随后，将此求解器作为核心物理引擎，构建逆分析的整体优化框架。通过定义模拟与观测误差的目标函数，并引入总变分等正则化项约束解的物理合理性。最终，利用 JAX 强大的自动微分功能，高效获取目标函数关于所有待反演参数的精确梯度，并将其与 Adam 等先进优化器相结合，形成一个完整的、端到端的梯度优化迭代流程。

(3) 数值实验与对比分析法：为全面验证所提方法的有效性和优越性，将设计并实施一系列系统的数值实验。通过设置不同非均质特征（如层状、含软弱夹层）的算例，并将反演结果与预设的“真实场”进行定量比较（如 L2 相对误差），来评估方法的反演精度。同时，将本方法的计算效率和反演效果与两种代表性的传统方法（基于有限差分的梯度法、粒子群优化（PSO）算法）进行横向对比，以凸显本方法在处理高维问题时的显著优势。此外，还将通过控制变量法，系统研究观测点稀疏度、数据噪声水平等关键因素对反演结果稳定性的影响。

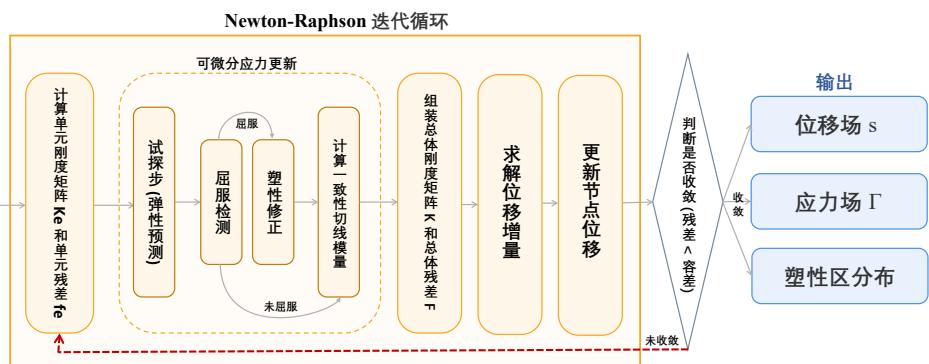


图 3 可微分正向求解器



图 4 参数反演全流程示意图

## 4.2 技术路线

本研究的技术路线如图所示，遵循“理论奠基-工具构建-方法验证-工程应用”的逻辑层次展开。首先，在岩石力学、有限元法及自动微分等理论基础上，构建并验证核心计算工具——可微分弹塑性有限元求解器。随后，以此为引擎搭建集成了正则化与梯度优化的高维逆分析框架，并通过一系列数值实验与传统方法对比，系统评估其性能。最终，将该方法应用于隧道开挖这一典型工程场景，检验其解决实际问题的能力，并在此基础上进行总结与展望。

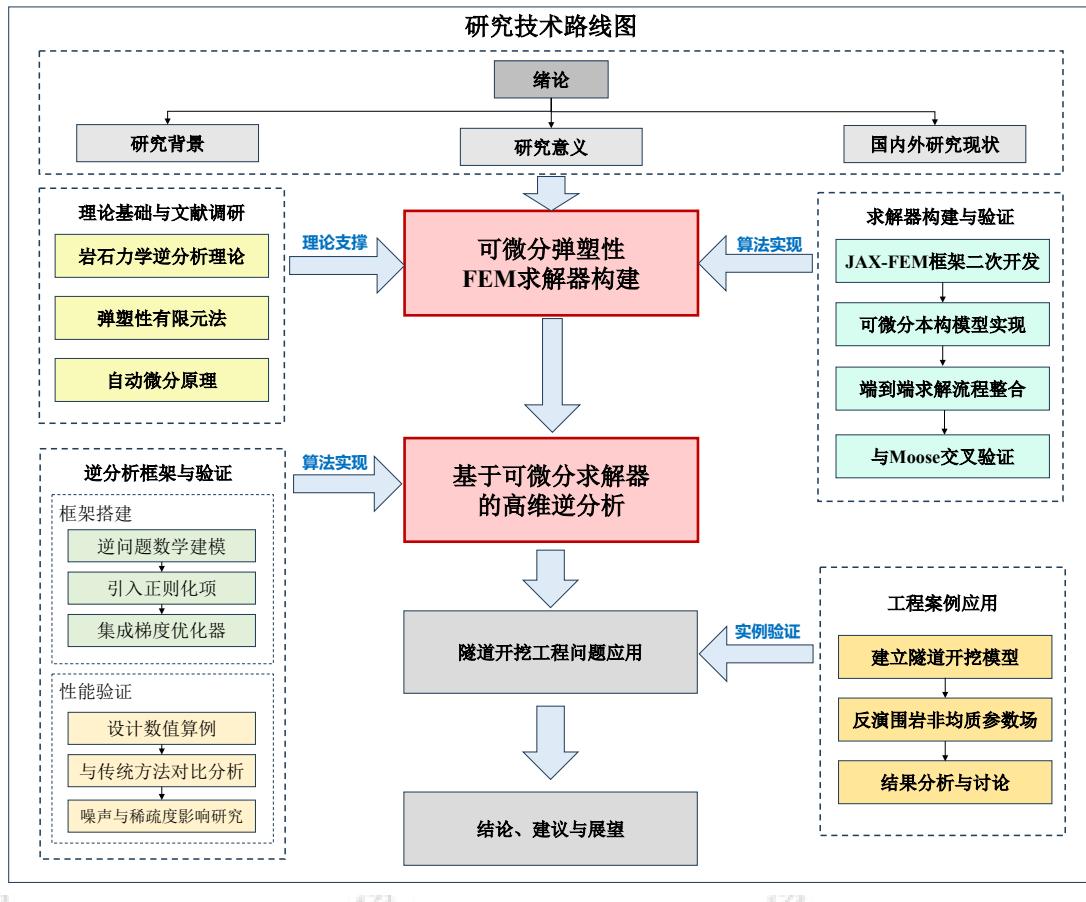


图 5 技术路线图

## 五、进度安排和预期成果

### 5.1 预期研究进展

2025 年 12 月至 2026 年 02 月，系统调研国内外相关文献，明确并细化研究方案，深入学习 JAX 可微分编程框架及 JAX-FEM 库，完成开题报告及论文绪论部分的撰写；

2026 年 03 月至 2026 年 06 月，基于 JAX 框架实现可微分弹塑性本构模型，构建并调试完整的可微分有限元求解器，并通过与商业软件对比完成交叉验证，撰写求解器构建章节；

2026 年 07 月至 2026 年 10 月，搭建集成正则化项的逆分析框架，设计并完成典型地质条件下的合成数据反演实验，初步验证方法的反演精度与效率；

2027 年 11 月至 2027 年 1 月，将所提方法与传统逆分析方法进行系统性对比，深入分析噪声、观测数据稀疏度等因素对反演结果的影响，并根据研究结果撰写第一篇学术论文；

2027 年 02 月至 2027 年 04 月，将方法应用于隧道开挖等工程实例，完成学位论文的最终撰写、修改与整合，准备毕业答辩。

### 5.2 预期成果

(1) 构建一个可微分的弹塑性有限元求解器，并在此基础上建立一套完整、高效的高维岩体力学参数逆分析计算框架。

(2) 提出一种基于可微分物理仿真的岩石力学逆分析新范式，旨在精确、高效地解决传统方法在高维非均质场反演中面临的“维度灾难”与“梯度困境”问题。

(3) 基于本研究的理论与数值成果，撰写并发表 SCI/EI 检索的高水平学术论文 1~2 篇（中科院分区 3 区以上）。

## 六、已有基础(与本项目有关的工作积累和已取得的成绩、已具备的条件)

### 6.1 申请人扎实的前期工作基础

申请人在研一阶段已为本项目构建了坚实的学科知识体系。

一方面，在物理驱动的深度学习领域具备深厚的实践经验。申请人并非只停留在理论学习，而是独立完成了两个与 PINNs 相关的开源项目。其一聚焦于网络架构的创新探索，体现了对算法底层原理的深刻理解；其二为面向应用的多保真数据融合架构，锻炼了解决实际问题的工程能力。这些经历使申请人对利用神经网络求解偏微分方程、处理逆问题以及应对数据稀疏性等挑战有深入的见解，且对自动微分这一核心技术有深刻理解，以及技术层面的经验。

另一方面，目前申请人在日本北海道大学岩石力学实验室进行交换，这为本项目提供了宝贵的交叉视野和数据支持。该实验室在岩石断裂力学、数值分析及并行化 FDEM 在岩土工程中的应用等领域处于国际前沿。在此期间，申请人不仅能接触到前沿的岩石力学与数值模拟研究，还能在浓厚的学术氛围中，将自己擅长的 PINNs 等前沿算法与经典的、经过工程检验的有限元/离散元方法进行思想碰撞，深刻理解不同方法的优势与局限。这段经历让我理解了“数据驱动模型”与“传统物理模型”的区别与联系，为本项目“构建可微分物理求解器”这一核心任务提供了独特的视角和方法论启发。

### 6.2 课题组的研究支撑

本课题组在岩土工程基础理论与学科交叉研究领域深耕多年，拥有强大的指导力量和丰硕的研究成果，可为本项目提供强有力的支撑。

指导力量方面，课题组拥有澳大利亚工程院院士一位，国家优秀青年基金获得者一位，湖南省杰出青年基金获得者一位。导师团队长期从事岩土工程基础理论与学科交叉研究，能够为本研究提供前瞻性的引领和细致的指导。

研究成果方面，课题组在将前沿算法应用于岩土工程方面积累了丰富的经验，尤其在物理信息神经网络（PINNs）的应用与改进上成果显著。至今，课题组已在相关领域发表论文四十余篇，例如：在国际顶级非线性动力学期刊《Chaos》上发表的关于改进 PINNs 的论文被选为期刊特色文章；在国际岩土核心期刊《Computers and Geotechnics》上发表了利用 PINNs 重构非饱和渗流场的文章；在国内顶级期刊《岩土工程学报》上发表了“PINNs 算法及其在岩土工程中的应用研究”等多篇重要文章。这些在“物理驱动的深度学习”方向上的深厚积累，为本项目探索可微分物理仿真这一新范式提供了坚实的理论与方法论支持。

### 6.3 完备的软硬件条件

本项目的实施拥有海内外双重软硬件保障。

硬件方面，国内课题组配备了 2 台艮泰高性能工作站及中南大学高性能计算中心服务器资源。同时，申请人在北海道大学交换期间，可使用实验室配备的顶级计算工作站，该工作站搭载了 4 块 NVIDIA A100 高性能 GPU，能为本项目中大规模、高并行的可微分计算与梯度优化任务提供可靠的算力支持。

软件方面，本研究将完全基于 Python 开源生态系统，使用 JAX、JAX-FEM 等免费、前沿的科学计算库，无需依赖昂贵的商业软件授权，确保了研究工作的灵活性与可扩展性。

## 七、主要参考文献

- [1] 何般鹏, 孙新建, 张野, 等. 隧洞围岩参数反演智能融合模型与分析方法[J]. 水力发电学报, 2021, 40(4): 156-166.
- [2] 关永平, 宋建, 王述红, 等. 基于 GA-BP 算法的隧道围岩力学参数反分析[J]. 东北大学学报(自然科学版), 2012, 33(2): 331-335.
- [3] 张升, 兰鹏, 苏晶晶, 等. 基于 PINNs 算法的地下水渗流模型求解及参数反演[J]. 岩土工程学报, 2023, 45(2): 421-430.
- [4] 刘开云, 方昱, 刘保国. 基于进化高斯过程回归算法的隧道工程弹塑性模型参数反演[J]. 岩土工程学报, 2011, 33(6): 941-947.
- [5] 毛凤山, 陈昌富, 朱世民. 代理模型方法及其在岩土工程中的应用综述[J]. 地基处理, 2020, 2(4): 29-39.
- [6] Bradbury J, Frostig R, Hawkins P, et al. JAX: composable transformations of Python+NumPy programs[EB/OL]. 2018. <http://github.com/google/jax>.
- [7] Chen R T Q, Rubanova Y, Bettencourt J, et al. Neural Ordinary Differential Equations[C]// Advances in Neural Information Processing Systems (NeurIPS), 2018, Montreal.
- [8] De Avila Belbute-Peres F, Smith K, Allen K, et al. End-to-end differentiable physics for learning and control[C]// Advances in Neural Information Processing Systems (NeurIPS), 2018, Montreal.
- [9] Schenck C, Fox D. Differentiable Physics-based Reconstruction of Human Performance[C]// IEEE International Conference on Robotics and Automation (ICRA), 2021, Xi'an: 12387-12393.
- [10] Sanchez-Gonzalez A, Godwin J, Pfaff T, et al. Learning to Simulate Complex Physics with Graph Networks[C]// International Conference on Machine Learning (ICML), 2020, Virtual.
- [11] Martinsson O, Funken J, Jonsson M. JAX-FEM: A differentiable finite element library for JAX[J]. Journal of Open Source Software, 2022, 7(76): 4405.
- [12] Geilinger S, Spielberg A, Rus D, et al. Differentiable simulation of soft-body dynamics[C]// International Conference on Learning Representations (ICLR), 2020, Virtual.
- [13] Liang J, Fang M, Liu X. Differentiable Projective Dynamics[J]. ACM Transactions on Graphics (TOG), 2019, 38(6): 1-13.
- [14] Li J, Wang Y, Matusik W, et al. Differentiable cloth simulation for inverse problems[C]// Advances in Neural Information Processing Systems (NeurIPS), 2019, Vancouver.
- [15] Murthy J K, Gole D, Turan M, et al. gradSim: Differentiable simulation for system identification and visuomotor control[C]// Conference on Robot Learning (CoRL), 2021, London.
- [16] Gioda G, Sakurai S. Inverse analysis in geotechnical engineering: a review[J]. International Journal for Numerical and Analytical Methods in Geomechanics, 1987, 11(6): 555-575.
- [17] Singh B, Singh U K. A review of inverse analysis for rock mass deformability[J]. International Journal of Rock Mechanics and Mining Sciences, 2004, 41(6): 1039-1049.
- [18] Zoccarato C, Gajo A. Identification of geomechanical parameters using the Ensemble Kalman Filter[J]. International Journal for Numerical and Analytical Methods in Geomechanics, 2018, 42(5): 695-723.

- [19] Zhang W G, Goh A T C, Zhang Y M, et al. Inverse analysis of a tunnel using a novel hybrid intelligent algorithm[J]. *Computers and Geotechnics*, 2012, 45: 93-102.
- [20] Guntu R K, Gunturi V R. Bayesian identification of the spatially variable rock mass properties of a Himalayan slope[J]. *Engineering Geology*, 2020, 273: 105658.
- [21] Wang L, Li L, Li J. Characterization of spatially variable rock mass properties using a Bayesian approach[J]. *Computers and Geotechnics*, 2017, 89: 139-152.
- [22] Goh A T C, Zhang W, Zhang Y, et al. Inverse analysis of deep excavation based on a support vector machine[J]. *International Journal for Numerical and Analytical Methods in Geomechanics*, 2014, 38(10): 1047-1061.
- [23] Raissi M, Perdikaris P, Karniadakis G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. *Journal of Computational Physics*, 2019, 378: 686-707.
- [24] He Q, Sudicky E. Reconstructing unsaturated infiltration behavior with sparse data via physics-informed deep learning[J]. *Computers and Geotechnics*, 2022, 147: 104728.
- [25] Chen Y, Lu L, Karniadakis G E, et al. Physics-informed neural networks for inverse problems in nano-optics and plasmonics[J]. *Optics Express*, 2020, 28(8): 11618-11633.
- [26] Zhang D, Lu L, Guo L, et al. A physics-informed deep learning paradigm for geostatistical simulation[J]. *Journal of Computational Physics*, 2021, 441: 110353.
- [27] Haghigat E, Bekemeyer P, Cyron C J. Solving elastoplasticity problems using physics-informed neural networks[J]. *Computer Methods in Applied Mechanics and Engineering*, 2021, 385: 114033.
- [28] Fuhr J N, Bouklas N. Physics-informed neural networks for solid mechanics: A review[J]. *GAMM-Mitteilungen*, 2022, 45(2): e202200005.
- [29] Wang S, Yu X, Perdikaris P. When and why PINNs fail to train: A neural tangent kernel perspective[J]. *Journal of Computational Physics*, 2022, 468: 111287.
- [30] Ishibashi T, Nitschke F, Fujii Y, et al. A coupled thermal-hydraulic-mechanical-chemical (THMC) model for interpretation of the stimulation mechanisms in an enhanced geothermal system[J]. *Geothermics*, 2019, 82: 274-287.
- [31] Shimizu H, Murata S, Ishida T. Development of a three-dimensional numerical model for the simulation of hydraulic fracturing and its validation[J]. *International Journal of Rock Mechanics and Mining Sciences*, 2011, 48(7): 1097-1108.
- [32] Zhang C, Fujii Y, Fukuda D. Application of convolutional neural network for rock type classification using hyperspectral image[J]. *Journal of the Mining and Materials Processing Institute of Japan*, 2020, 136(1): 1-8.
- [33] Nagai K, Sato K, Sugawara K. A numerical study on the influence of natural fractures on the hydraulic fracturing process[J]. *Rock Mechanics and Rock Engineering*, 2005, 38(1): 1-21.
- [34] Ongie G, Jalal A, Metzler C A, et al. Deep learning for inverse problems in imaging[J]. *IEEE Journal on Selected Areas in Information Theory*, 2020, 1(2): 314-331.
- [35] Lu L, Meng X, Mao Z, et al. DeepXDE: A deep learning library for solving differential equations[J].

SIAM Review, 2021, 63(1): 208-228.

- [36] Finno R J, Calvello M. A comprehensive study of non-uniqueness in the inverse problem of a deep excavation[J]. Computers and Geotechnics, 2005, 32(4): 276-290.
- [37] Li Z, Kovachki N, Azizzadenesheli K, et al. Fourier Neural Operator for Parametric Partial Differential Equations[C]// International Conference on Learning Representations (ICLR), 2021, Virtual.
- [38] Baydin A G, Pearlmutter B A, Radul A A, et al. Automatic differentiation in machine learning: a survey[J]. Journal of Machine Learning Research, 2018, 18(153): 1-43.
- [39] Tartakovsky A M, Marrero C O, Perdikaris P, et al. Inverse-problem-solving with physics-informed neural networks: an application in subsurface hydrogeology[J]. Advances in Water Resources, 2020, 145: 103679.
- [40] Avrashi I, Gendelman O V. A gradient-based method for the identification of a spatially-varying elastic modulus from full-field displacement data[J]. International Journal of Solids and Structures, 2017, 122-123: 129-142.
- [41] Hoyer S, Sohl-Dickstein J, Greff K. Topology optimization using the finite element method and a differentiable physics solver[R]. arXiv preprint arXiv:1910.08591, 2019.
- [42] Zhang Z, Sun W, Liu W K. Differentiable plasticity for texture evolution[J]. Computer Methods in Applied Mechanics and Engineering, 2022, 396: 115001.
- [43] Bar-Sinai Y, Hoyer S, Hickey J, et al. Learning data-driven discretization for partial differential equations[J]. Proceedings of the National Academy of Sciences, 2019, 116(25): 12235-12240.
- [44] Fuks O, Tchelepi H A. A review of data-driven and physics-informed methodologies for surrogate modeling of subsurface transport[J]. Journal of Computational Physics, 2022, 464: 111183.
- [45] Jia X, Willard J, Karpatne A, et al. A general framework for data-driven, physics-informed, and physics-based modeling of dynamical systems[R]. arXiv preprint arXiv:2105.08843, 2021.

**八、指导教师意见**

指导教师签字:

日期:

**九、专家评审意见**

评审小组成员	姓名	职称	工作单位	本人签名
组长				
成员				
秘书				

评审意见:

评定等级(在□内打“√”选择):

优秀(□A+、□A、□A-)

良好(□B+、□B、□B-)

合格(□C+、□C、□C-)

不合格(□D)

评审小组组长签字:

日期:

**十、所在二级单位意见**

负责人签字:

(单位盖章)日期: